

T2 Decisión

Índice

1. Introducción (revisión de PER)
2. Ejercicio
3. Clasificación sensible al coste
4. Clasificación con opción de rechazo
5. Matrices de confusión binarias
6. Curvas ROC
7. Curvas PR
8. F-scores

1 Introducción (revisión de PER)

Inferencia Bayesiana: cálculo de la **posterior** $p(H \mid \mathbf{x})$ mediante la regla de Bayes actualizar nuestras creencias sobre cantidades ocultas H a partir de datos \mathbf{x}

Teoría de la decisión Bayesiana: usa la inferencia para decidir cuál es la mejor de las posibles **acciones** a realizar

Agente: debe escoger una acción de un conjunto de acciones posibles, \mathcal{A}

Estado de la naturaleza: $h \in \mathcal{H}$, condiciona los costes y beneficios que se derivan de tomar cada acción posible

Función de pérdida: indica el coste incurrido al tomar la acción $a \in \mathcal{A}$ cuando el estado de la naturaleza es $h \in \mathcal{H}$

$$\ell(h, a)$$

Riesgo (pérdida) esperado a posteriori: de a tras observar \mathbf{x}

$$R(a \mid \mathbf{x}) = \mathbb{E}_{p(h|\mathbf{x})}[\ell(h, a)] = \sum_{h \in \mathcal{H}} \ell(h, a) p(h \mid \mathbf{x})$$

Política óptima o estimador de Bayes: obtiene una acción de mínimo riesgo por cada observación posible

$$\pi^*(\mathbf{x}) = \operatorname{argmin}_{a \in \mathcal{A}} R(a \mid \mathbf{x})$$

Problemas de clasificación

Estados de la naturaleza y acciones: etiquetas de clase, $\mathcal{H} = \mathcal{Y} = \{1, \dots, C\}$ y $\mathcal{A} = \mathcal{Y}$

Pérdida 01 esperada a posteriori: la probabilidad de error a posteriori es uno menos la de acertar a posteriori

$$R(\hat{y} \mid \mathbf{x}) = \sum_y \ell_{01}(y, \hat{y}) p(y \mid \mathbf{x}) = \sum_{y \neq \hat{y}} p(y \mid \mathbf{x}) = 1 - p(\hat{y} \mid \mathbf{x})$$

Esstimator de Bayes: $\pi(\mathbf{x}) = \operatorname{argmax}_{y \in \mathcal{Y}} p(y \mid \mathbf{x})$ estimador MAP o moda de la posterior

Matriz de confusión: $\mathcal{D} = \{(y_m, \hat{y}_m)\}$, $\mathbf{M} = [M_{y,\hat{y}}]$ con $M_{y,\hat{y}} = \sum_m \mathbb{I}(y_m = y) \mathbb{I}(\hat{y}_m = \hat{y})$

y	$\hat{1}$	$\hat{2}$	\dots	\hat{C}	Suma fila
1	$M_{1,\hat{1}}$	$M_{1,\hat{2}}$	\dots	$M_{1,\hat{C}}$	$M_{1,:}$
2	$M_{2,\hat{1}}$	$M_{2,\hat{2}}$	\dots	$M_{2,\hat{C}}$	$M_{2,:}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
C	$M_{C,\hat{1}}$	$M_{C,\hat{2}}$	\dots	$M_{C,\hat{C}}$	$M_{C,:}$
Suma:	$M_{:, \hat{1}}$	$M_{:, \hat{2}}$	\dots	$M_{:, \hat{C}}$	M

Normalización por filas: estimación empírica de $p(\hat{y} \mid y)$

Normalización por columnas: estimación empírica de $p(y \mid \hat{y})$

Normalización por filas y columnas: estimación empírica de $p(y, \hat{y})$

Análisis de una clase específica: se reduce a matriz binaria tomando el resto de clases como clase negativa

Problemas de regresión

Estados de la naturaleza y acciones: reales, $\mathcal{H} = \mathcal{A} = \mathcal{Y} = \mathbb{R}$

Pérdida L2 (ℓ_2 , cuadrática o error cuadrático): $\ell_2(h, a) = (h - a)^2$

Pérdida L2 esperada a posteriori:

$$R(a \mid \mathbf{x}) = \mathbb{E}[(h - a)^2 \mid \mathbf{x}] = \mathbb{E}[h^2 \mid \mathbf{x}] - 2a\mathbb{E}[h \mid \mathbf{x}] + a^2$$

Regresor de Bayes L2 o minimum mean squared error (MMSE): media a posteriori

$$\frac{\partial}{\partial a} R(a \mid \mathbf{x}) = -2\mathbb{E}[h \mid \mathbf{x}] + 2a = 0 \quad \rightarrow \quad \pi(\mathbf{x}) = \mathbb{E}[h \mid \mathbf{x}] = \int h p(h \mid \mathbf{x}) dh$$

2 Ejercicio

Agente: un médico debe tratar un paciente que podría tener COVID y las posibles acciones son: no hacer nada o dar una medicina con efectos secundarios graves, pero que podría salvarle la vida

Estado de la naturaleza: el estado viene dado por la edad del paciente (joven o mayor) y si tiene COVID o no; se trata de un estado *parcialmente observado* ya que podemos observar la edad del paciente directamente, pero no si tiene COVID o no, cosa que modelizamos probabilísticamente mediante un test

Función de pérdida: medimos costes en quality-adjusted life years (QALYs); asumimos que el coste de dar una medicina es de 8 QALYs, independientemente del estado del paciente; sin embargo, el coste de no dar nada a un paciente con COVID se considera de 60 QALYs si es joven; 10 si es mayor

Estado	nada	med.
Joven, no COVID	0	8
Joven, COVID	60	8
Mayor, no COVID	0	8
Mayor, COVID	10	8

Ejercicio: Por cada posible observación parcial de estado, halla el riesgo esperado a posteriori de cada acción y determina una acción de menor riesgo; asume que la observación parcial de estado viene representada por un vector de datos \boldsymbol{x} que incluye edad (joven o mayor) y resultado del test (0 o 1). Si el test resulta positivo (1), tanto si es joven como mayor, la probabilidad de que tenga COVID es 0.795455. Si resulta negativo, la probabilidad de que tenga COVID es 0.014045.

Solución:

edad	test	pr(covid)	nada	med.	acción
joven	0	0.014045	0.842697	8.00	nada
joven	1	0.795455	47.727273	8.00	med.
mayor	0	0.014045	0.140449	8.00	nada
mayor	1	0.795455	7.954545	8.00	nada

$$\mathcal{H} = \{(J, \bar{C}), (J, C), (M, \bar{C}), (M, C)\} \quad \mathcal{A} = \{N, M\}$$

$$R(N | J0) = \ell(J\bar{C}, N) p(J\bar{C} | J0) + \ell(JC, N) p(JC | J0) = 0 \cdot (1 - 0.014045) + 60 \cdot 0.014045 = 0.8427$$

$$R(M | J0) = \ell(J\bar{C}, M) p(J\bar{C} | J0) + \ell(JC, M) p(JC | J0) = 8 \cdot (1 - 0.014045) + 8 \cdot 0.014045 = 8$$

$$R(N | J1) = \ell(J\bar{C}, N) p(J\bar{C} | J1) + \ell(JC, N) p(JC | J1) = 0 \cdot (1 - 0.795455) + 60 \cdot 0.795455 = 47.7273$$

$$R(M | J1) = \ell(J\bar{C}, M) p(J\bar{C} | J1) + \ell(JC, M) p(JC | J1) = 8 \cdot (1 - 0.795455) + 8 \cdot 0.795455 = 8$$

$$R(N | M0) = \ell(M\bar{C}, N) p(M\bar{C} | M0) + \ell(MC, N) p(MC | M0) = 0 \cdot (1 - 0.014045) + 10 \cdot 0.014045 = 0.140450$$

$$R(M | M0) = \ell(M\bar{C}, M) p(M\bar{C} | M0) + \ell(MC, M) p(MC | M0) = 8 \cdot (1 - 0.014045) + 8 \cdot 0.014045 = 8$$

$$R(N | M1) = \ell(M\bar{C}, N) p(M\bar{C} | M1) + \ell(MC, N) p(MC | M1) = 0 \cdot (1 - 0.795455) + 10 \cdot 0.795455 = 7.95455$$

$$R(M | M1) = \ell(M\bar{C}, M) p(M\bar{C} | M1) + \ell(MC, M) p(MC | M1) = 8 \cdot (1 - 0.795455) + 8 \cdot 0.795455 = 8$$

3 Clasificación sensible al coste

Pérdida para dos clases con costes distintos: $\mathcal{Y} = \{0, 1\}$

$$\ell(y^*, \hat{y}) = \begin{pmatrix} \ell_{00} & \ell_{01} \\ \ell_{10} & \ell_{11} \end{pmatrix}$$

Pérdida esperada a posteriori: $p_0 = p(y^* = 0 \mid \mathbf{x})$ y $p_1 = 1 - p_0$

$$R(\hat{y} \mid \mathbf{x}) = \sum_{y^*} \ell(y^*, \hat{y}) p(y^* \mid \mathbf{x}) = \begin{cases} \ell_{00} p_0 + \ell_{10} p_1 & \text{si } \hat{y} = 0 \\ \ell_{01} p_0 + \ell_{11} p_1 & \text{si } \hat{y} = 1 \end{cases}$$

Estimador de Bayes:

$$\pi^*(\mathbf{x}) = \begin{cases} 0 & \text{si } \ell_{00} p_0 + \ell_{10} p_1 < \ell_{01} p_0 + \ell_{11} p_1 \\ 1 & \text{si no} \end{cases}$$

Coste de acierto nulo: $\ell_{00} = \ell_{11} = 0$

$$\pi^*(\mathbf{x}) = \begin{cases} 0 & \text{si } \ell_{10} p_1 < \ell_{01} p_0 \\ 1 & \text{si no} \end{cases} = \begin{cases} 0 & \text{si } p_1 < \frac{\ell_{01}}{\ell_{01} + \ell_{10}} \\ 1 & \text{si no} \end{cases}$$

... y falso negativo c veces más caro que falso positivo: $\ell_{10} = c\ell_{01}$

$$\pi^*(\mathbf{x}) = \begin{cases} 0 & \text{si } p_1 < \frac{1}{1+c} \\ 1 & \text{si no} \end{cases}$$


4 Clasificación con opción de rechazo

Pérdida con opción de rechazo (acción 0): $\mathcal{H} = \mathcal{Y} = \{1, \dots, C\}$ y $\mathcal{A} = \mathcal{Y} \cup \{0\}$

$$\ell(y^*, a) = \begin{cases} 0 & \text{si } a \in \mathcal{Y} \text{ y } a = y^* \\ \lambda_r & \text{si } a = 0 \\ \lambda_e & \text{otro caso} \end{cases}$$

Estimador de Bayes: sean $y^* = \operatorname{argmax}_{y \in \mathcal{Y}} p(y | \mathbf{x})$, $p^* = p(y^* | \mathbf{x})$ y $\lambda^* = 1 - \frac{\lambda_r}{\lambda_e}$

$$\pi^*(\mathbf{x}) = \begin{cases} y^* & \text{si } p^* > \lambda^* \\ 0 & \text{en otro caso} \end{cases}$$



5 Matrices de confusión binarias

Clasificación binaria: caso particular de gran interés con una clase positiva (1) y otra negativa (-1 o 0)

Caso típico: la positiva es a priori (mucho) más improbable que la negativa y, sobre todo, queremos acertar con las muestras positivas; por ejemplo, para confirmar un diagnóstico médico hipotético a partir del resultado de una prueba

Clasificador basado en un umbral $\tau \in [0, 1]$: τ puede verse como un **margen** de positividad

$$\hat{y}_\tau(\mathbf{x}) = \mathbb{I}(p(y=1 \mid \mathbf{x}) \geq 1 - \tau)$$

Elección de τ : no tomamos $\tau = 0.5$ y ya está, sino que variamos τ de 0 a 1 y estudiamos $\hat{y}_\tau(\mathbf{x})$

- **Caso $\tau = 0$:** solo acertamos positivos "seguros", esto es, tal que $p(y=1 \mid \mathbf{x}) = 1$
- **Caso $\tau = 1$:** acertamos todos los positivos a cambio de clasificar también como positivos todos los negativos
- **Caso $0 < \tau < 1$:** al aumentar τ acertamos más positivos y confundimos más negativos pero, ¿a qué ritmo?

Matriz de confusión binaria: tras clasificar M muestras (de test) con un τ dado

y	$\hat{0}$	$\hat{1}$	Suma fila
0	TN_τ (true negatives)	FP_τ (false positives)	N
1	FN_τ (false negatives)	TP_τ (true positives)	P
Suma	\hat{N}_τ	\hat{P}_τ	M

Normalización por filas: estimación empírica de $p(\hat{y} \mid y)$

y	$\hat{0}$	$\hat{1}$	Suma fila
0	TNR_τ	FPR_τ	1.0
1	FNR_τ	TPR_τ	1.0

- $TNR_\tau = TN_\tau / N$ es el **true negative (rate)** o **specificity**
- $FPR_\tau = FP_\tau / N$ es el **false positive (rate)**, **false alarm**, **type I error** o **fallout**
- $FNR_\tau = FN_\tau / P$ es el **false negative (rate)**, **miss** o **type II error**
- $TPR_\tau = TP_\tau / P$ es el **true positive (rate)**, **hit**, **recall** o **sensitivity**

Normalización por columnas: estimación empírica de $p(y \mid \hat{y})$

\hat{y}	$\hat{0}$	$\hat{1}$
0	NPV_τ	FDR_τ
1	FOR_τ	PPV_τ
Suma	1.0	1.0

- $NPV_\tau = TN_\tau / \hat{N}_\tau$ es el **negative predictive value**
- $FOR_\tau = FN_\tau / \hat{N}_\tau$ es el **false omission rate**
- $FDR_\tau = FP_\tau / \hat{P}_\tau$ es el **false discovery rate**
- $PPV_\tau = TP_\tau / \hat{P}_\tau$ es el **positive predictive value** o **precision**


6 Curvas ROC

Propósito: estudiar el comportamiento de un clasificador binario $\hat{y}_\tau(\mathbf{x}) = \mathbb{I}(p(y=1 \mid \mathbf{x}) \geq 1 - \tau)$ en función de τ

Curva Receiver Operating Characteristic (ROC): TPR_τ en función de la FPR_τ , para todo τ de 0 a 1

Curvas ROC típicas: de dos clasificadores, A y B, siendo el A claramente mejor que el B

```
In [ ]: import numpy as np; import matplotlib.pyplot as plt
fA = np.vectorize(lambda x: x**(1.0/3)); fB = np.vectorize(lambda x: x**(2.0/3)); x = np.arange(0, 1, 0.01)
plt.figure(figsize=(3.5,3)); plt.plot(x, 1-x, 'k-')
plt.plot(x, fA(x), 'r-'); plt.plot(x, fB(x), 'b-'); plt.fill_between(x, fB(x), 0, facecolor='cyan')
inter_a = 0.3177; # found using scipy.optimize.fsolve(x**(1.0/3)+x-1, 0)
inter_b = 0.4302; # found using scipy.optimize.fsolve(x**(2.0/3)+x-1, 0)
plt.plot(inter_a, fA(inter_a), 'ro'); plt.plot(inter_b, fB(inter_b), 'bo')
plt.text(inter_a, fA(inter_a) + 0.05, 'A', color='red', size='x-large')
plt.text(inter_b, fB(inter_b) + 0.05, 'B', color='blue', size='x-large')
plt.xlabel(r'$FPR_{\{\tau\}}$', size='large'); plt.ylabel(r'$TPR_{\{\tau\}}$', size='large');
```



Curva ROC de un clasificador perfecto: si $p(y = 1 \mid \mathbf{x}) = 1$ para las muestras positivas y 0 para las negativas, la curva ROC se reduce a un punto en la esquina superior izquierda y otro en la superior derecha

- $\tau < 1$: $FPR_\tau = \frac{FP_\tau}{N} = \frac{0}{N} = 0$ y $TPR_\tau = \frac{TP_\tau}{P} = \frac{P}{P} = 1$
- $\tau = 1$: $FPR_1 = \frac{FP_1}{N} = \frac{N}{N} = 1$ y $TPR_1 = \frac{TP_1}{P} = \frac{P}{P} = 1$

Curva ROC de un clasificador aleatorio: si $p(y = 1 \mid \mathbf{x}) = \text{Unif}(0, 1)$, la curva ROC es una recta diagonal

$$FPR_\tau = \frac{FP_\tau}{N} \approx \frac{N \cdot \tau}{N} = \tau \quad \text{y} \quad TPR_\tau = \frac{TP_\tau}{P} \approx \frac{P \cdot \tau}{P} = \tau$$

Curva ROC de un clasificador realista: monótona creciente por encima de la diagonal (mejor cuanto más arriba)

- $\tau = 0$: la curva ROC empieza en la esquina inferior izquierda o un poco más arriba; $FPR_0 = 0$ y $TPR_0 \geq 0$
- $\tau = 1$: la curva ROC termina en la esquina superior derecha; $FPR_1 = TPR_1 = 1$
- $0 < \tau < 1$: la curva ROC es monótona creciente (y por encima de la diagonal)

$$\tau' \leq \tau \quad \rightarrow \quad FPR_{\tau'} \leq FPR_\tau \quad \text{y} \quad TPR_{\tau'} \leq TPR_\tau$$

Resumen de un curva ROC mediante un escalar: para facilitar su comparación con otras curvas

- **Área bajo la curva (AUC, area under curve):** en la figura ejemplo, la AUC de A es mejor (mayor) que la de B (en azul)
- **Equal error rate (EER) o cross-over rate:** valor de FPR_τ tal que $FPR_\tau = FNR_\tau = 1 - TPR_\tau$, esto es, abscisa del punto en el que la curva ROC cruza la diagonal que va de la esquina superior izquierda a la inferior derecha; en la figura ejemplo, la EER de A (rojo) es mejor (menor) que el de B (azul)

7 Curvas PR

Propósito: estudiar $\hat{y}_\tau(\mathbf{x}) = \mathbb{I}(p(y=1 | \mathbf{x}) \geq 1 - \tau)$ en función de τ y con especial atención a positivos ya que la noción de "negativo" está muy abierta (p. ej. en detección de objetos, recuperación de información o clasificación abierta)


Precisión y recall (cobertura): positivos predicho-verdaderos sobre predichos y verdaderos

$$\mathcal{P}(\tau) = \frac{\text{TP}_\tau}{\text{TP}_\tau + \text{FP}_\tau} = \frac{\text{TP}_\tau}{\hat{P}_\tau} = \text{PPV}_\tau \quad \text{y} \quad \mathcal{R}(\tau) = \frac{\text{TP}_\tau}{\text{TP}_\tau + \text{FN}_\tau} = \frac{\text{TP}_\tau}{P} = \text{TPR}_\tau$$

Curva precision-recall (PR): $\mathcal{P}(\tau)$ en función de $\mathcal{R}(\tau)$, para todo τ de 0 a 1

Curvas PR típicas: de dos clasificadores, A y B, siendo el A claramente mejor que el B

```
In [ ]: import numpy as np; import matplotlib.pyplot as plt
fA = np.vectorize(lambda x: 1 - x**3); fB = np.vectorize(lambda x: 1 - x**(3/2)); x = np.arange(0, 1, 0.01)
plt.figure(figsize=(3,2.5)); plt.axis([0, 1, 0, 1.01]); plt.plot(x, fA(x), 'r-'); plt.plot(x, fB(x), 'b-')
plt.text(0.6, 0.82, 'A', color='red', size='x-large'); plt.text(0.2, 0.78, 'B', color='blue', size='x-large')
plt.xlabel(r'$\mathcal{R}(\tau)$', size='large'); plt.ylabel(r'$\mathcal{P}(\tau)$', size='large');
```



Curva PR de un clasificador perfecto: si $p(y = 1 | \mathbf{x}) = 1$ para las muestras positivas y 0 para las negativas, la curva PR se reduce a un punto en $(1, 1)$ y otro en $(1, P/M)$

- $\tau < 1$: $\mathcal{P}(\tau) = \frac{\text{TP}_\tau}{\hat{P}_\tau} = \frac{P}{P} = 1$ y $\mathcal{R}(\tau) = \frac{\text{TP}_\tau}{P} = \frac{P}{P} = 1$
- $\tau = 1$: $\mathcal{P}(\tau) = \frac{\text{TP}_\tau}{\hat{P}_\tau} = \frac{P}{M}$ y $\mathcal{R}(\tau) = \frac{\text{TP}_\tau}{P} = \frac{P}{P} = 1$

Curva PR de un clasificador aleatorio: si $p(y = 1 | \mathbf{x}) = \text{Unif}(0, 1)$, es una recta horizontal a altura P/M

$$\mathcal{P}(\tau) = \frac{\text{TP}_\tau}{\hat{P}_\tau} \approx \frac{P \cdot \tau}{M \cdot \tau} = \frac{P}{M} \quad \text{y} \quad \mathcal{R}(\tau) = \frac{\text{TP}_\tau}{P} \approx \frac{P \cdot \tau}{P} = \tau$$

Curva PR de un clasificador realista: aprox. monótona decreciente por encima de P/M (mejor cuanto más arriba)

- $\tau = 0$: asumiendo que se predice algún positivo, es de esperar una precisión alta y cobertura baja (próxima a 0)
- $\tau = 1$: punto $(1, P/M)$
- $0 < \tau < 1$: curva **aproximadamente** monótona decreciente

$$\tau' \leq \tau \rightarrow \mathcal{R}(\tau') \leq \mathcal{R}(\tau) \quad \text{pero} \quad \tau' \leq \tau \not\rightarrow \mathcal{P}(\tau') \geq \mathcal{P}(\tau)$$

Curva PR interpolada: sustituye $\mathcal{P}(\tau)$ por $\max_{\tilde{\tau} \geq \tau} \mathcal{P}(\tilde{\tau})$ para suavizar la curva haciéndola monótona decreciente

Resumen de un curva PR mediante un escalar: para facilitar su comparación con otras curvas

- **Área bajo la curva PR o average precision (AP):** en la figura ejemplo, la AP de A es mejor (mayor) que la de B
- **Mean average precision (mAP):** AP media de varias curvas PR; p. ej. de cada clase en clasificación multiclase
- **mAP@_:** mAP limitada, p. ej. a las K muestras más probables o un cierto subconjunto de umbrales

8 F-scores

Propósito: establecer una única medida que evalúe adecuadamente la calidad de cualquier par precisión-cobertura

F-scores: F_β con $\beta \geq 0$ da β veces más importancia a la cobertura que a la precisión

$$F_\beta = (1 + \beta^2) \frac{\mathcal{P}\mathcal{R}}{\beta^2\mathcal{P} + \mathcal{R}} \quad \text{o} \quad \frac{1}{F_\beta} = \frac{1}{1 + \beta^2} \frac{1}{\mathcal{P}} + \frac{\beta^2}{1 + \beta^2} \frac{1}{\mathcal{R}}$$

Casos particulares en función de la β :

- $\beta = 0$: da nula importancia a la cobertura frente a la precisión; de hecho, $F_0 = \mathcal{P}$
- $\beta = 0.5$: da la mitad de importancia a la cobertura que a la precisión
- $\beta = 1$: da la misma importancia a la cobertura que a la precisión y coincide con la **media armónica** de ambas


$$F_1 = 2 \frac{\mathcal{P}\mathcal{R}}{\mathcal{P} + \mathcal{R}} = \frac{2}{\frac{1}{\mathcal{R}} + \frac{1}{\mathcal{P}}}$$

- $\beta = 2$: da el doble de importancia a la cobertura que a la precisión
- $\beta \rightarrow \infty$: da infinita importancia a la cobertura frente a la precisión

$$\lim_{\beta \rightarrow \infty} F_\beta = \lim_{\beta \rightarrow \infty} \frac{\mathcal{P}\mathcal{R}}{\beta^2\mathcal{P} + \mathcal{R}} + \lim_{\beta \rightarrow \infty} \frac{\mathcal{P}\mathcal{R}}{\mathcal{P} + \frac{\mathcal{R}}{\beta^2}} = \mathcal{R}$$

Comparación gráfica: F_β en función de \mathcal{P} y \mathcal{R} , para $\beta \in (1, 0.5, 2)$; también media aritmética

```
In [ ]: import numpy as np; import matplotlib.pyplot as plt
R, P = np.meshgrid(np.linspace(0.01, 1, 100), np.linspace(0.01, 1, 100)); RP = np.c_[np.ravel(R), np.ravel(P)]
B = (1, 0.5, 2); nrows = 1; ncols = len(B) + 1 # len(B) plots de F + plot de media
_, axs = plt.subplots(nrows=nrows, ncols=ncols, figsize=(16, 14*nrows/ncols), constrained_layout=True)
for ax, b in zip(axs.flat[:-1], B):
    bsquared = np.square(b)
    F = lambda rp: (1 + bsquared) * rp.prod() / (bsquared * rp[1] + rp[0]); FF = np.apply_along_axis(F, 1, RP)
    ax.set_title(f"beta = {b}"); ax.set_xlabel('R'); ax.set_ylabel('P')
    ax.contour(R, P, FF.reshape(R.shape), 10, colors='orange', linestyles='solid')
    cp = ax.contourf(R, P, FF.reshape(R.shape), 10, cmap='Blues_r'); plt.colorbar(cp, ax=ax)
ax = axs.flat[-1]; A = RP.mean(axis = 1); ax.set_title(f"media aritmética"); ax.set_xlabel('R'); ax.set_ylabel('P')
ax.contour(R, P, A.reshape(R.shape), 10, colors='orange', linestyles='solid')
cp = ax.contourf(R, P, A.reshape(R.shape), 10, cmap='Blues_r'); plt.colorbar(cp, ax=ax);
```



Observaciones que se derivan de la comparación gráfica:

- F_1 : sus curvas de nivel son simétricas respecto a la diagonal, por lo que precisión y cobertura contribuyen con la misma importancia, si bien ambas deben ser elevadas para que F_1 también lo sea
- F_β con $\beta < 1$ (p. ej. $\beta = 0.5$): las curvas de nivel de F_β tienden a horizontalizarse, esto es, F_β se approxima a \mathcal{P}
- F_β con $\beta > 1$ (p. ej. $\beta = 2$): las curvas de nivel F_β tienden a verticalizarse, por lo que F_β se approxima a \mathcal{R}
- **Media aritmética:** parecida a F_1 , pero crece mucho con precisiones cuasi-nulas (hasta 0.5 con $\mathcal{P} = 0$)

F-scores con $C > 2$ clases: consideramos C casos binarios, uno por cada clase frente al resto

Macro average F1: media de los scores F1 de las clases

$$\text{MacroF1} = \frac{1}{C} \sum_c F_1^{(c)}$$

Weighted average F1: media de los scores F1 de las clases, ponderados por las probabilidades a priori de clase

$$\text{WeightedF1} = \sum_c \hat{p}(c) F_1^{(c)}$$

Micro average F1: F_1 global, calculado a partir de precisión y cobertura globales o, más directamente, a partir verdaderos-positivos, falsos-negativos y falsos-positivos globales

$$\text{MicroF1} = 2 \frac{\mathcal{P}\mathcal{R}}{\mathcal{P} + \mathcal{R}} = 2 \frac{\frac{\text{TP}}{\text{TP} + \text{FP}} \cdot \frac{\text{TP}}{\text{TP} + \text{FN}}}{\frac{\text{TP}}{\text{TP} + \text{FP}} + \frac{\text{TP}}{\text{TP} + \text{FN}}} = \frac{\text{TP}}{\text{TP} + \frac{1}{2}(\text{FN} + \text{FP})}$$

Ejercicio: calcula F1 macro, weighted y micro a partir de la siguiente matriz de confusiones

y	$\hat{1}$	$\hat{2}$	$\hat{3}$
1	2	1	0
2	0	1	0
3	1	2	3

Solución:

y	$\text{TP}^{(y)}$	$\text{FP}^{(y)}$	$\text{FN}^{(y)}$	$\mathcal{P}^{(y)}$	$\mathcal{R}^{(y)}$	$F_1^{(y)}$	$\hat{p}(y)$
1	2	1	1	2/3	2/3	2/3	3/10
2	1	3	0	1/4	1/1	2/5	1/10
3	3	0	3	3/3	3/6	2/3	6/10

$$\text{MacroF1} = \frac{1}{3} \left(\frac{2}{3} + \frac{2}{5} + \frac{2}{3} \right) = \frac{26}{45} = 0.58$$

$$\text{WeightedF1} = \frac{3}{10} \cdot \frac{2}{3} + \frac{1}{10} \cdot \frac{2}{5} + \frac{6}{10} \cdot \frac{2}{3} = \frac{48}{75} = 0.64$$

$$\text{MicroF1} = \frac{\text{TP}}{\text{TP} + \frac{1}{2}(\text{FN} + \text{FP})} = \frac{6}{6 + \frac{1}{2}(4 + 4)} = \frac{3}{5} = 0.60$$